WOJSKOWA AKADEMIA TECHNICZNA



Sprawozdanie z przedmiotu Teoria Informacji i Kodowania Prowadzący: Pisula Małgorzata

Wykonawca: Kawka Maciej, 76797, WCY20IY2S1

1. Opis zadania.

1.1. Cel zadania.

Celem zadania jest zaimplementowanie tzw. Kodowania Huffmana, czyli metody kompresji bezstratnej w celu kompresji oraz dekompresji plików.

1.2. Opis teoretyczny.

Kodowanie Huffmana składa się z 5 etapów:

- 1. Obliczanie ilości występowania każdego symbolu z pliku.
- 2. Posortowanie otrzymanego zbioru symboli i ich częstotliwości.
- 3. Utworzenie drzewa kodowego.
- 4. Zapisanie nowych kodów znaków na podstawie drzewa kodowego do tablicy kodowej.
- 5. Zapisanie skompresowanego pliku za pomocą odczytanych znaków.

2. Opis wykonanego programu.

2.1. Obliczenie ilość występowania każdego symbolu z pliku.

Pierwszym punktem omawianej metody jest utworzenie modelu źródła informacji, czyli zestawienia każdego symbolu oraz ilości jego występowania w pliku. W prezentowanym programie dane te będą trzymane w tablicy, której identyfikator istnieje pod nazwą huffmanModelArray.

```
struct HuffmanNode* huffmanModelArray = (HuffmanNode*)malloc(sizeof(HuffmanNode) * 1);
```

Rysunek 1 .Alokacja pamięci dla tablicy kodowej

W celu wypełnienie tablicy potrzeba odczytać i policzyć wszystkie symbole w pliku. Program wykonuję to za pomocą funkcji GenerateModelFromFile.

```
huffmanModelArray = GenerateModelFromFile(huffmanModelArray, &iter, &checkSum);
```

Rysunek 2. Wywołanie funkcji GenerateModelFromFile

```
struct HuffmanNode *GenerateModelFromFile(struct HuffmanNode *huffmanModelArray, int* it, int* ch) {
   FILE* inputFileHandle = fopen(inputFile, "rb");
   int readCount = 0;
   unsigned char buffer[1];
   int readBytesLength = 1;
   int iter = 0;
   int temp = 0, checkSum = 0;
    //huffmanModelArray = (HuffmanNode*)malloc(sizeof(HuffmanNode) * 1);
   while (readCount = fread(buffer, sizeof(unsigned char), readBytesLength, inputFileHandle)) {
        readCount += 1;
        temp = IsItInArray(huffmanModelArray, buffer[0], iter);
       if (temp != 0) {
           huffmanModelArray[temp - 1].frequency += 1;
       }
        else {
            huffmanModelArray = (HuffmanNode*)realloc(huffmanModelArray, sizeof(HuffmanNode) * ((iter)+1));
            huffmanModelArray[iter].symbol = (int)buffer[0];
           huffmanModelArray[iter].parent = -1;
           huffmanModelArray[iter].left = -1;
           huffmanModelArray[iter].right = -1;
           huffmanModelArray[iter].frequency = 1;
           iter++:
       3
        checkSum += 1;
    fclose(inputFileHandle);
    //printf("Przed sortowaniem:\n");
    int i;
   //for (i = 0; i < iter; i++) {
     // printf("%d:%d\n", huffmanModelArray[i].symbol, huffmanModelArray[i].frequency);
   //}
   *it = iter;
    *ch = checkSum;
   return huffmanModelArray;
}
```

Rysunek 3. Funkcja GenerateModelFromFile.

Powyższa funkcja w pętli while, odczytuje kolejne bajty z pliku i zapisuję je do zmiennej typu unsigned char o nazwie buffer. W pętli jest wywoływana funkcja "IsItInArray", która sprawdza czy w tablicy huffmanModelArray został zapisany już symbol o danym kodzie i zwraca liczbę jeśli tak, a -1 jeśli nie.

```
// This functions returns 0 if there is no symbol like this in buffor and if there is some like that it returns it position in array
int IsItInArray(HuffmanNode huffmanModelArray[MODEL_ARR_LEN], int buffer, int iter) {
    int i;
    for (i = 0; i < iter; i++) {
        if (huffmanModelArray[i].symbol == buffer) {
            return i + 1;
        }
    }
    return 0;
}</pre>
```

Rysunek 4. Funkjca IsltInArray

Zwracana wartość jest zapisywana do zmiennej temp i na jej podstawie dokonywany jest wybór. Jeżeli temp ma wartość 0 to znaczy, że dany symbol jeszcze nie został wczytany i w związku z tym

należy zaalokować dodatkową pamięć dla tablic znaków i zapisać tam dany znak. Jeżeli temp ma wartość inną niż 0 to oznacza, że temp-1 to jest to indeks w tablicy pod którym znajduje się wczytany znak, a więc należy zwiększyć o jeden licznik jego wystąpień.

Warto wspomnieć o strukturze, z której zbudowana jest tablica huffmanModelArray.

```
typedef struct HuffmanNode {
   int symbol;
   int frequency;
   //struct HuffmanTreeNode *left, *right, *parent;
   int left, right, parent;
}HuffmanNode;
```

Rysunek 5. Struktura HuffmanNode, z której stworzona jest tablica huffmanModelArray

Zawiera ona dodatkowe parametry typu o nazwach left, right i parent w celu dalszego przekształcenia tablicy w drzewo kodowe o konstrukcji takiej, że zmienne left, right i parent będą indeksami w tablicy.

2.2. Posortowanie otrzymanego zbioru symboli i ich częstotliwości.

Sortowanie tablicy symboli odbywa się za pomocą funkcji SortHuffmanModel.

```
SortHuffmanModel(iter, huffmanModelArray);

Rysunek 6. Wywofanie funkcji SortHuffmanModel

int CompareHuffmanNodes(const void* item1, const void* item2) {
    HuffmanNode* node1 = (HuffmanNode*)item1;
    HuffmanNode* node2 = (HuffmanNode*)item2;
    //printf("Node 1: %d : %d \n", (*node1).symbol, (*node1).frequency);
    //printf("Node 2: %d : %d \n", node2->symbol, node2->frequency);
    int compareResult = (node1->frequency - node2->frequency);
    if (compareResult == 0) {
        compareResult = (node1->symbol - node2->symbol);
    }
    return -compareResult;
}

void SortHuffmanModel(int modelArrayLength, struct HuffmanNode *huffmanModelArray) {
        qsort(huffmanModelArray, modelArrayLength, sizeof(HuffmanNode), CompareHuffmanNodes);
}
```

Rysunek 7. Funkcja SortHuffmanModel

Jest to funkcja, która wykorzystuje algorytm quicksort do posortowania tablicy.

2.3. Utworzenie drzewa kodowego.

Drzewo kodowe tworzone jest na bazie tablicy huffmanModelArray za pomocą funkcji GenerateHuffmanTreeFromModel.

```
huffmanModelArray = GenerateHuffmanTreeFromModel(huffmanModelArray, iter, checkSum, &root);
```

Rysunek 8. Wywołanie funkcji GenerateHuffmanTreeFromModel

```
struct HuffmanNode *GenerateHuffmanTreeFromModel(struct HuffmanNode *huffmanModelArray, int iter, int checkSum, int *root) {
   int lastNode = iter-1, leftNode, rightNode, nodeSpecial = 1001;
   while(huffmanModelArray[iter-1].frequency != checkSum)
       FindSmallestNode(&leftNode, &rightNode, huffmanModelArray, iter);
       huffmanModelArray = (struct HuffmanNode*)realloc(huffmanModelArray, sizeof(HuffmanNode) * ((iter)+1));
       huffmanModelArray[iter].symbol = nodeSpecial;
       huffmanModelArrav[iter].left = leftNode:
       huffmanModelArray[iter].right = rightNode;
       huffmanModelArray[iter].frequency = huffmanModelArray[leftNode].frequency + huffmanModelArray[rightNode].frequency;
       huffmanModelArray[iter].parent = -1;
       huffmanModelArray[leftNode].parent = iter;
       huffmanModelArray[rightNode].parent = iter;
       //printf("w funkcji %d\n", iter/*huffmanModelArray[iter].frequency*/);
       iter++:
       nodeSpecial++:
   //printf("pytanie %d ", huffmanModelArray[iter-1].right);
   iter = iter-1:
   *root = iter;
       //printf("w funkcji %d\n", huffmanModelArray[iter].frequency);
   return huffmanModelArray;
3
```

Rysunek 9. Funkcja GenerateHuffmanTreeFromModel

Działanie funkcji jest następujące. W pętli znajdowane są 2 najmniejsze wiersze tablicy kodowej. Następnie tworzony jest nowy wiersz tablicy, który staję się rodzicem dwóch mniejszych, a jego częstotliwość jest sumą częstotliwości dwóch ówcześnie znalezionych wierszy. Jest to wykonywane jedynie dla tych wierszy, w których parent jest równy -1, ponieważ kiedy ta zmienna przyjmuję taką wartość to znaczy, że element nie ma jeszcze rodzica, a to oznacza, że dalej bierze udział w tworzeniu drzewa. Pętla wykonuję się aż do czasu, kiedy badany element nie będzie miał frequency odpowiadającego liczbie wszystkich znaków w tekście. Warto omówić to na podstawie przykładu.

W tablicy kodowej zapisane jest 5 elementów drzewa kodowego.

Index	1	2	3	4	5
Symbol	а	b	С	d	е
Częstotliwość	3	5	2	6	10
Lewy id	-1	-1	-1	-1	-1
Prawy id	-1	-1	-1	-1	-1
Rodzic	-1	-1	-1	-1	-1

Wartości w wszystkich kolumnach w wierszach Lewy id, Prawy id, Rodzic są ustawione na –1 już w pierwszym kroku implementacji. Dzięki temu można rozróżnić, które symbole w tablicy odpowiadające za magazynowanie symboli. Symbole zawszę będą miały wartości -1 na indeksie lewego oraz prawego dziecka. Kiedy rodzic jest ustawiony na –1 oznacza to, że są brane pod uwagę w wybieraniu kolejnych elementów dla drzewa.

Index	1	2	3	4	5	6
Symbol	a	b	С	d	е	a+b
Częstotliwość	3	5	2	6	10	5
Lewy id	-1	-1	-1	-1	-1	3
Prawy id	-1	-1	-1	-1	-1	1

Rodzic	6	-1	6	-1	-1	-1
NOUZIC	U		0	_	-	_

Po pierwszej iteracji został dodany nowy element tablicy o indeksie 6. Nie ma on rodzica, ponieważ jest to nowy element, a jego potomkami są elementy o indeksach 1 i 3. Można zauważyć, że zmienił się rodzic w nowo połączonych elementach i jest on ustawiony na 6. Przez to w następnej iteracji pętli nie będą już one analizowane.

Index	1	2	3	4	5	6	7
Symbol	а	b	С	d	е	a+b	B+id 6
Częstotliwo ść	3	5	2	6	10	5	10
Lewy id	-1	-1	-1	-1	-1	3	2
Prawy id	-1	-1	-1	-1	-1	1	6
Rodzic	6	7	6	-1	-1	7	-1

Jak widać w powyższej tabeli, został utworzony nowy element o indeksie 7, który połączył elementy 2 i nowy element 6. Jak widać rodzicem w 2 i 6 jest teraz 7, a więc nie będą one brane więcej pod uwagę.

To postępowanie algorytm wykonuję aż do momentu, kiedy ostatni element będzie miał częstotliwość, równą ilości znaków w każdym tekście. Warto zauważyć, że ostatnim elementem tablicy będzie korzeń.

Poniżej zamieszczam jeszcze funkcje odpowiedzialną za wybór 2 kolejnych elementów tablicy, w każdej iteracji.

```
void\ FindSmallestNode(int\ *1N,\ int\ *rN,\ struct\ HuffmanNode\ *huffmanModelArray,\ int\ iter)\ \{
   int i, leftNodeMin = 2147483647, rightNodeMin = 2147483647, leftNode, rightNode;
    for (i = 0; i < iter; i++) {
       if (huffmanModelArray[i].frequency <= leftNodeMin && huffmanModelArray[i].parent == -1) //patrze tylko tam gdzie nie ma rodzica
           leftNode = i:
           leftNodeMin = huffmanModelArray[i].frequency;
       }
    3
    for (i = 0; i < iter; i++) {
       if (huffmanModelArray[i].frequency <= rightNodeMin && huffmanModelArray[i].parent == -1 && i != leftNode)
           rightNode = i;
           rightNodeMin = huffmanModelArray[i].frequency;
   }
    //printf("\n",i);
    if (leftNode == rightNode)
       printf("\n-----\n");
    *1N = leftNode;
    *rN = rightNode;
```

Rysunek 10. Funkcja FindSmallestNode.

Został zastosowany tutaj sposób na zwracanie więcej niż jednej wartości za pomocą odpowiedniego manipulowania wskaźnikami.

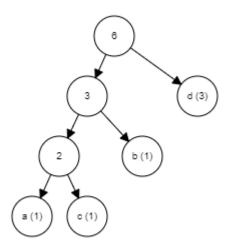
2.4. Zapisanie nowych kodów znaków na podstawie drzewa kodowego do tablicy kodowej.

Po wygenerowaniu drzewa należy utworzyć tablice kodową w celu późniejszego wykorzystania jej do zapisania tablicy kodowej. Poniżej zamieszczam linijkę kodu, która uruchamia funkcję odpowiedzialną za to zadanie.

GenerateCodeTableFromTree(root, arr, top, huffmanModelArray, fileForCode);

Rysunek 11. Wywołanie funkcji GenerateCodeTableFromTree.

W kodowaniu Huffmana symbol otrzymuję swój znak na podstawie drzewa kodowego. W celu wytłumaczenia zasady działania algorytmu posłużę się przykładem ze strony https://cmps-people.ok.ubc.ca/ylucet/DS/Huffman.html.



Rysunek 12. Przykład drzewa kodowego.

Załóżmy że plik pozwolił wygenerować takie drzewo Huffmana jak na rysunku powyżej. Aby od korzenia dostać się do znaku "a" należy wybrać 3-krotnie drogę w lewo. W kodowaniu Huffmana dogra w lewo oznacza 0, a w prawo 1, więc kodem znaku "a" jest "000". Na tej samej zasadzie możemy określić kod znaku "c", należy pójść 2-krotnie w lewo i na koniec w prawo, a więc kod znaku "c" to "001".

Z powyższego rozumowania wynikają, następujące wniosek: aby określić kod każdego znaku potrzeba znać jego drogę od korzenia aż do liścia, w którym zapisany jest dany znak. Taką możliwość daje algorytm przeszukiwania drzewa "post-order". Tak właśnie działa funkcja GenerateCodeTableFromTree.

```
void GenerateCodeTableFromTree(int root, int arr[], int top, struct HuffmanNode *huffmanModelArray, FILE *outFileH) {
   if (huffmanModelArray[root].left != -1) {
       arr[top] = 0;
       GenerateCodeTableFromTree(huffmanModelArray[root].left, arr, top + 1, huffmanModelArray,outFileH);
    if (huffmanModelArray[root].right != -1) {
       arr[top] = 1;
       {\tt GenerateCodeTableFromTree(huffmanModelArray[root].right, arr, top + 1, huffmanModelArray,outFileH);} \\
   if (huffmanModelArray[root].left == -1 && huffmanModelArray[root].right == -1) {
       //fprintf(outputFileCodeTable, "%d-", root->symbol);
       //printf("%d-", huffmanModelArray[root].symbol);
       fprintf(outFileH,"%d-", huffmanModelArray[root].symbol);
       for (i = 0; i < top; i++) {
               //printf("%d",arr[i]);
               fprintf(outFileH, "%d", arr[i]);
               }
       //printf("\n");
       fprintf(outFileH,"\n");
}
```

 $Ry sunek\ 13.\ Funkcja\ Generate Code Table From Tree.$

Funkcja przeszukuję rekurencyjnie drzewo w kierunku post-order, przekazując do następnych wywołań funkcji dotychczas odczytany kod. Po każdym przejściu dopisuje to tablicy arr kolejne 0 lub 1 zależnie od tego czy "poszło" w lewo lub w prawo. Tablice przekazuję do następnych wywołań, tak aby wywołanie funkcji, które na trafi na liść (wierzchołek którego lewy i prawy potomek są równe -1 czyli nie istnieje ich potomstwo) wypisało znak i jego kod do pliku.

W tym punkcie dobrze też poruszyć temat funkcji zapisującej drzewo do pliku. Funkcja nosi nazwę WriteHuffmanTreeToFile.

```
void WriteHuffmanTreeToFile(struct HuffmanNode *huffmanModelArray, int size) {
                  FILE* outputFileH:
                  if ((outputFileH = fopen(outputFileTreeF, "w")) == NULL) {
                  printf("Otwieranie pliku do zapisu %s nie powiodlo sie\n", outputFile);
         int i;
                 for (i = 0; i <= size; i++)
                  {
                                     if (huffmanModelArray[i].symbol >= 1000) {
                                                       //printf("#%d", huffmanModelArray[i].symbol - 1000);
                                                       fprintf(outputFileH,"#%d", huffmanModelArray[i].symbol - 1000);
                                     }
                                     else {
                                                        //printf("%d", huffmanModelArray[i].symbol);
                                                       fprintf(outputFileH,"%d", huffmanModelArray[i].symbol);
                                     //printf(":%d", huffmanModelArray[i].frequency);
                                     fprintf(outputFileH, ":%d", huffmanModelArray[i].frequency);
                                     if (huffmanModelArray[huffmanModelArray[i].left].symbol >= 1000 && huffmanModelArray[i].left != -1) {
                                                       //printf("\tchildLeft:#%d", huffmanModelArray[huffmanModelArray[i].left].symbol - 1000);
                                                       fprintf(outputFileH,"\tchildLeft:#%d", huffmanModelArray[huffmanModelArray[i].left].symbol - 1000);
                                      \textbf{else if } (\texttt{huffmanModelArray[i].left].symbol == 0 || \texttt{huffmanModelArray[i].left} == -1) \ \{ \texttt{left} : \texttt{left} := -1 \} \ \{ \texttt{left} : \texttt{left
                                                       //printf("\tchildLeft:-");
                                                       fprintf(outputFileH, "\tchildLeft:-");
                                     else {
                                                       //printf("\tchildLeft:%d", huffmanModelArray[huffmanModelArray[i].left].symbol);
                                                       fprintf(outputFileH, "\tchildLeft:%d", huffmanModelArray[huffmanModelArray[i].left].symbol);
                                     }
                                      if (huffmanModelArray[huffmanModelArray[i].right].symbol >= 1000 \& huffmanModelArray[i].right != -1) \{ (huffmanModelArray[i].right != -1) \} 
                                                       //printf("\tchildRight:#%d", huffmanModelArray[huffmanModelArray[i].right].symbol - 1000);
                                                       fprintf(outputFileH, "\tchildRight: \# d", huffmanModelArray[huffmanModelArray[i].right]. symbol - 1000);
                                     else if (huffmanModelArray[huffmanModelArray[i].right].symbol == 0 || huffmanModelArray[i].right == -1) {
                                                       //printf("\tchildRight:-");
                                                       fprintf(outputFileH,"\tchildRight:-");
                                     }
                                     else {
                                                        //printf("\tchildRight:%d", huffmanModelArray[huffmanModelArray[i].right].symbol);
                                                       fprintf(outputFileH,"\tchildRight:%d", huffmanModelArray[huffmanModelArray[i].right].symbol);
                                     if (i == size) {
                                                        //printf("\tParent:-");
                                                       fprintf(outputFileH,"\tParent:-");
                                     else {
                                                       if (huffmanModelArray[huffmanModelArray[i].parent].symbol >= 1000) {
                                                                          //printf("\tParent: \#\%d", \ huffmanModelArray[huffmanModelArray[i].parent]. symbol \ - \ 1000);
                                                                          fprintf(outputFileH,"\tParent:#%d", huffmanModelArray[huffmanModelArray[i].parent].symbol - 1000);
                                                       else if (huffmanModelArray[huffmanModelArray[i].parent].symbol == -1) {
                                                                           //printf("\tParent:-");
                                                                          fprintf(outputFileH, "\tParent:-");
```

Rysunek 14. Funkcja GenerateCodeTableFromTree.

Jest to bardzo prosta funkcja, ponieważ całe drzewo jest zapisane w tablicy, więc funkcja po prostu wykonuję pętle for tak długo, az wpisze całą tablicę do pliku. Wszystkie konstrukcje if są po to, aby drzewo zostało zapisane w odpowiednim formacie.

Poniżej zamieszczam również funkcję, która zapisuję model źródła danych do pliku. Funkcja ta również wypisuję elementy tablicy w pętli jednak w momencie, w którym funkcja ta się wykonuję to jeszcze nie ma utworzonego drzewa na podstawie tablicy, a więc wypiszą się tylko te elementy tablicy, które są znakami.

```
void WriteModelToFile(int iter, struct HuffmanNode *huffmanModelArray) {
   FILE* outputFileHandle;
   if ((outputFileHandle = fopen(outputFileModel, "w")) == NULL) {
      printf("Otwieranie pliku do zapisu %s nie powiodlo sie\n", outputFile);
   }
   else {
      fprintf(outputFileHandle, "%d\n", iter);
      int i;
      for (i = 0; i < iter; i++) {
            fprintf(outputFileHandle, "%d\%d\n", huffmanModelArray[i].symbol, huffmanModelArray[i].frequency);
      }
   }
   fclose(outputFileHandle);
}</pre>
```

Rysunek 15. Funkcja WriteModelToFile.

2.5. Zapisać skompresowany plik z pomoca odczytanych znaków.

Sekwencje zapisu skompresowanego pliku rozpoczyna wczytanie tablicy kodowej z pliku utworzonego w poprzednim punkcie. Tablica kodowa zostanie zapisana do tablicy, której typem jest struktura o nazwie CodeDock.

```
typedef struct CodeDock {
    int sign;
    int current;
    unsigned int code;
}CodeDock;
```

Rysunek 16. Struktura CodeDock.

Tablica kodowa zostaje zapisana do tablicy w programie za pomocą funkcji CodeDockCreate.

```
struct CodeDock *CodeDockCreate(int *toPass) {
       FILE *inFileH:
       CodeDock *cDock;
       unsigned char bufor[1];
       int iter = 0, mode = 1, count = 0, first = 1;
       if((inFileH = fopen(outputFileCodeTab, "r")) == NULL) {
               printf("Nie znaleziono pliku\n");
               return NULL;
       cDock = (CodeDock*)malloc(sizeof(CodeDock));
       cDock[iter].sign = 0;
       while (fread(bufor, sizeof(unsigned char), 1, inFileH)) {
               //printf("%c", bufor[0]);
               if (bufor[0] == '-') {
                        first = 0;
                       cDock[iter].code = 0x00;
                       cDock[iter].current = 0;
                       continue:
                }
                if (bufor[0] == '\n') {
                        //printf("Code Table: %d 0x%X\n", cDock[iter].sign, cDock[iter].code);
                       cDock = (CodeDock*)realloc(cDock, sizeof(CodeDock)*(iter+1));
                       cDock[iter].sign = 0;
                       first = 1;
                       continue;
                }
                if (first) {
                        cDock[iter].sign = cDock[iter].sign*10 + bufor[0] - 48;
                        //printf("buffor: %c to to: %d ", bufor[0], cDock[iter].sign);
                }
                else {
                       cDock[iter].code = cDock[iter].code << 1;</pre>
                       cDock[iter].code += bufor[0] - 48;
                        cDock[iter].current += 1;
                }
       }
        *toPass = iter;
       fclose(inFileH);
       return cDock;
```

Rysunek 17. Funkcja CodeDockCreate.

Funkcja działa na podstawie pętli while, w której każda jej iteracja wczytuje kolejny bajt, aż do końca pliku. Program zapisuję do tablicy cDock kolejne znaki. Kiedy zmienna first jest ustawiona na 1 to znaczy, że zapisuję symbol tablicy kodowej a więc jakąś liczbe typu int. W programie wczytujemy kolejne znaki tej tablicy, a więc żeby wczytać cały liczbę oznaczającą znak należy następną wczytaną cyfrę pomnożyć dodać do poprzedniej wartości razy 10. Cyfry w alfabecie ASCII są reprezentowane od indexu 48, a więc żeby zapisać sczytaną cyfrę należy odjąć od znaku ASCII liczbę 48. Jeżeli program natrafi w pliku na znak "-" to zmienna first zmieni się na 0 i program zacznie wczytywać kod znaku. Kod znaku jest czytany w ten sposób że początkowo ma wartość 0x00. Kiedy zostanie wczytany znak zwiększa się current o 1 oraz sam kod zostanie przesunięty binarnie o 1 w lewo i

zostanie do niego dodany znak ASCII –48 czyli 0 albo 1. Warto zwrócić uwagę na zwiększanie current z każdą iteracją. Dzięki temu w dalszej części programu będzie wiadomo, ile bitów, patrząc od lewej, z kodu reprezentuję kod. To działanie jest wykonywane aż do znalezienia znaku nowej linii i wtedy zostanie zaalokowane więcej pamięci na kolejny wiersz tablicy cDock oraz zmienna first znowu przyjmie wartość 1 co oznacza że znowu program będzie wczytywał liczbę, która jest reprezentacją znaku w ASCII.

Kolejną funkcją, która uczestniczy bezpośrednio w zapisaniu skompresowanego pliku jest WriteCompressedFile.

```
void WriteCompressedFile(CodeDock *codeTable, int limes) {
        FILE *input, *output;
        if((input = fopen(inputFile, "rb")) == NULL) {
               printf("Nie znaleziono pliku z danymi!\n");
        if((output = fopen(outputFile, "wb")) == NULL) {
                printf("Nie udalo sie utworzyc pliku!\n");
        }
        unsigned char bufor[1], bit, out = 0x00, mask;
        //unsigned int temp;
       int i,j, shift=8, tableShift;
       while(fread(bufor, sizeof(unsigned char), 1, input)) {
                for (i = 0; i < limes; i++) {</pre>
                        if (codeTable[i].sign == bufor[0]) {
                                tableShift = codeTable[i].current - 1;
                                for (j = 0; j < codeTable[i].current; j++) {</pre>
                                        if ( ((codeTable[i].code >> (tableShift - j)) & 0x00000001 ) != 0x00) {
                                                //printf("1");
                                                mask = 0x01;
                                        }
                                        else {
                                                mask = 0x00;
                                                //printf("0");
                                        mask = mask << shift;</pre>
                                        //printf("shift: %d", shift);
                                        out = out ^ mask;
                                        //tableShift--;
                                        if (shift == 0) {
                                                 shift = 8;
                                                fprintf(output, "%c", out);
                                                //printf(" %X ",out);
                                                out = 0x00;
                                        }
                               }
                        }
                }
        }
        if (shift != 0) {
               fprintf(output, "%c", out);
        fclose(input);
        fclose(output);
}
```

Rysunek 18. Funkcja WriteCompressedFile.

Głównym elementem tej funkcji jest pętla while, która czyta kolejne bajty wejściowego, nieskompresowanego pliku do zmiennej bufor. W pętli jest kolejna pętla for, która wykonuję się tyle razy, ile wierszy ma tablica codeTable, która jest tablicą ze znakami i ich kodami, wczytana w poprzedniej funkcji. Zmienna bufor jest porównywana z tablicą kodową i kiedy symbol jest taki sam jak w tablicy to funkcja przystępuję do utworzenia bajtu do zapisania do pliku. Niedogodnością języka c w tym przypadku jest to, że minimalna ilość danych, którą możemy zapisać do pliku jest jeden bajt. Dlatego należy go najpierw uzupełnić i potem zapisać. Zmienna out reprezentuję bajt do zapisania do pliku. Na początku ustawiana jest wartość tableShift która jest o jeden mniejsza niż ilość

bitów którą trzeba wczytać. W pętli for, która wykona się tyle razy, ile ma wielkość w bitach kod znaku wpisywane jest po jednym bicie do zmiennej out. Aby wyłuskać kolejne bity będziemy sprawdzać w if wartość codeTable[i].code przesuwając ją o wartość tableShift – j (w ten sposób co iteracje pętli będziemy przesuwać o inną wartość tak że wartość do wpisania będzie zawsze na najmłodszej pozycji) i wykonywać operację and z wartością 1. Wtedy, jeżeli uzyskana wartość będzie równa 1, to oznacza to że powinniśmy do zmiennej out wpisać 1 a jeżeli 0 to powinniśmy dopisać 0. Oczywiście zależnie od uzyskanej jedynki lub zera zapisujemy do zmiennej mask odpowiednio 0x01 albo 0x00. Następnie mask jest przesuwane binarnie tak aby odpowiednio wypozycjonować 1 i jest xorowana z out. Dzięki temu uzyskamy na odpowiedniej pozycji w out bit 1 lub 0. Shift w każdej iteracji się zmienia, ponieważ musimy zapisywać bity na odpowiednich pozycjach. Kiedy shift przyjmie wartość 0 oznacza to, że zmienna out została w całości zapisana, a więc zapisujemy out do pliku oraz ustawiamy shift z powrotem na 8. Na koniec funkcji zapisujemy jeszcze zmienną out w momencie, gdy shift nie jest równy 0, ponieważ wtedy oznacza to że nie zapisaliśmy ostatniego bajtu, który ówcześnie już został wypełniony.

3. Dekompresja.

3.1. Odczytanie drzewa kodowego.

Dekompresja zaczyna się od odczytania drzewa kodowego. Pierwszą funkcją wykonywaną w tym celu jest funkcja CreateNotConfiguredList.

```
struct HuffmanNode *CreateNotConfiguredList(FILE *inFileH, int *ret) {
        unsigned char bufor[1];//, *fullFile = (unsigned char*)malloc(sizeof(unsigned char));
    int mode = 1, iter = 0, temp = 0, ofset = 0;
        struct HuffmanNode *code = (HuffmanNode*)malloc(sizeof(HuffmanNode));
    while (fread(bufor, sizeof(unsigned char), 1, inFileH)) {
       //printf("%c", bufor[0]);
       if (mode == 1) {
                if (bufor[0] == ':') {
                        code[iter].symbol = temp + ofset;
                        //printf("symbol: %d",code[iter].symbol);
                        //printf("symbol: %d",code[iter].symbol);
                        mode = 2; temp = 0; ofset = 0;
                        continue;
                        }
                        else if (bufor[0] == '#') {
                                ofset = 1000;
                        }
                        else {
                                temp = temp*10 + bufor[0] - 48;
                                //printf("symbol: %d",temp);
                        }
                }
                else if (mode == 2) {
                        if (bufor[0] == '\t') {
                                code[iter].frequency = temp;
                                //printf(" frequency: %d",code[iter].frequency);
                                mode = 3; temp = 0;
                                continue;
                        }
                        else {
                                temp = temp*10 + bufor[0] - 48;
                        }
                else if (mode == 3) {
                        if (bufor[0] == '\t') {
                                if (temp == -3) {
                                        code[iter].left = -1;
                                }
                                else {
                                        code[iter].left = temp + ofset;
                                //printf(" left: %d",code[iter].left);
                                mode = 4; temp = 0; ofset = 0;
                                continue;
                        else if ((bufor[0] >= 65 && bufor[0] <= 122) || bufor[0] == ':') {
                                continue;
                        else if (bufor[0] == '#') {
                                ofset = 1000;
                        }
                        else {
```

```
if (bufor[0] == '\t') {
                        if (temp == -3) {
                                code[iter].right = -1;
                        }
                        else {
                                code[iter].right = temp + ofset;
                        //printf(" right: %d",code[iter].right);
                        mode = 5; temp = 0; ofset = 0;
                        continue;
                }
                else if ((bufor[0] >= 65 && bufor[0] <= 122) || bufor[0] == ':') {
                        continue;
                }
                else if (bufor[0] == '#') {
                        ofset = 1000;
                }
                else {
                        temp = temp*10 + bufor[0] - 48;
                }
        }
        else if (mode == 5) {
                if ((int)bufor[0] == 10) {
                        if (temp == -3) {
                                code[iter].parent = -1;
                        else {
                                code[iter].parent = temp + ofset;
                        //printf(" parent: %d\n",code[iter].parent);
                        mode = 1; temp = 0; ofset = 0;
                        iter++;
                        code = (HuffmanNode*)realloc(code, sizeof(HuffmanNode)*(iter+2));
                        continue;
                }
                else if ((bufor[0] >= 65 && bufor[0] <= 122) || bufor[0] == ':') {
                        continue;
                }
                else if (bufor[0] == '#') {
                        //printf(" jest hasz ");
                        ofset = 1000;
                        continue;
                }
                else {
                        temp = temp*10 + bufor[0] - 48;
                        //printf(" temp: %d", temp);
                }
        }
*ret = iter;
return code;
```

else if (mode == 4) {

}

Funkcja ta wczytuję kolejne wiersze pliku z drzewem do tablicy code, która jest taką samą tablicą jak ta, która zawierała drzewo w trakcie kompresji. W wyniku tego wczytywania uzyskujemy tablicę, która jest delikatnie wypaczona. Jest ona taka z tego powodu, że nie ma po przypisywanych odpowiednich danych pod left, right i parent, a są wstawione zamiast indexów symbole znaków lub symbole innych wierzchołków, które w celu dalszej interpretacji są powiększone o 1000. W celu poprawnego skonfigurowania listy powstała funkcja ConfigureListToTree.

```
struct HuffmanNode *ConfigureListToTree(struct HuffmanNode *code, int size) {
        int i, index;
        for (i = 0; i < size; i++) {
                if (code[i].left > 0) {
                        index = getNodeIndex(code, size, code[i].left);
                        code[i].left = index;
                }
                if (code[i].right > 0) {
                        index = getNodeIndex(code, size, code[i].right);
                        code[i].right = index;
                }
                if (code[i].parent > 0) {
                        index = getNodeIndex(code, size, code[i].parent);
                        code[i].parent = index;
                }
        }
        return code;
}
```

Rysunek 20. Funkcja ConfigureListToTree.

Funkcja ta iteruję się po każdym wierszu z tablicy reprezentującej drzewo kodowe i tam gdzie wartość left, right lub parent, są większe od 0(ponieważ kiedy te nie ma tych wartości to w tamte miejsca wpisane jest -1) wywołuję funkcje getNodeIndex, która zwraca odpowiedni index do zapisania w left, right lub parent.

```
int getNodeIndex(struct HuffmanNode *code, int size,int symbol) {
    int i;
    for (i = 0; i < size; i++) {
        if (symbol == code[i].symbol) {
            return i;
        }
    }
    return 0;
}</pre>
```

Rysunek 21. Funkcja getNodeIndex.

Powyższa funkcja iteruję się po całej tablicy, w której zapisane jest drzewo binarne, a następnie zwraca odpowiedni index z tabeli, kiedy natrafi na zadany znak. W innym przypadku zwraca 0.

Ostatnią funkcja, która bierze udział w dekompresji jest WriteDecompressedFile.

```
void WriteDecompressedFile(HuffmanNode *code, int limes, int root) {
        FILE *inFileH;
        if ((inFileH = fopen(inputFile, "rb")) == NULL) {
            printf("Wystapil blad - niektore pliki sa niedostepne\n");
        }
        FILE *outFileH;
        if ((outFileH = fopen(outputFile, "wb")) == NULL) {
            printf("Wystapil blad - niektore pliki sa niedostepne\n", outputFileCodeTab);
        unsigned char bufor[1], mask = 0x00, temp = 0x00;
        int iter = 0, node = root;
        while (iter < limes) {
                if (mask == 0x00) {
                        fread(bufor, sizeof(unsigned char), 1, inFileH);
                        mask = 0x80;
                temp = bufor[0] & mask;
                if (temp) {
                        node = code[node].right;
                }
                else {
                        node = code[node].left;
                }
                mask = mask >> 1;
                if (code[node].left == -1 && code[node].right == -1) {
                        fprintf(outFileH, "%c", code[node].symbol);
                        node = root;
                        iter++;
                }
        //printf("%d ",iter);
        fclose(inFileH);
        fclose(outFileH);
}
```

Rysunek 22. Funkcja WriteDecompressedFile.

Funkcja ta działa w oparciu o pętle while, która będzie wykonywać się tak długo aż zmienna iter nie przyjmie wartości równej ilości wszystkich bajtów w pliku. Ilość ta została wcześniej odczytana z częstotliwości zapisanej w korzeniu drzewa.

Funkcja ta odczytuje znaki w następujący sposób. Po wczytaniu całego bajtu z skompresowanego pliku, "wyłuskuję" z niego jeden bit w każdej iteracji pętli. Wyłuskiwanie jest uzyskiwane za pomocą maski. Maska na początku ma wartość 0x00 co oznacza, że wykona się to co jest w pierwszym if czyli zostanie sczytany bajt z pliku skompresowanego oraz mask zostanie ustawione na 0x80. Oznacza to że mask ma jedynkę na pierwszym bicie. Dzięki temu po wykonaniu operacji and z bajtem sczytanym z pliku, w zmiennej temp zostanie zapisana wartość 0 lub inna w zależności od tego czy ten pierwszy bit to 0 lub 1. Mask z każdą iteracją jest poddawane operacji przesunięciu binarnego w prawo dzięki

czemu 1 będzie przechodziło od pierwszej do ostatniej pozycji w bajcie i po operacji and będziemy wiedzieć, czy odczytaliśmy 0 czy 1. W zależności od tego czy odczytaliśmy 0 czy 1, zmieniamy indeks, który reprezentuje nam miejsce w drzewie kodowym. W takim razie, kiedy jest 0 to zmienna node przyjmuję wartość indeksu lewego potomka, a jeżeli 1 to przyjmuje wartość prawego potomka. Kiedy dojdziemy tymi iteracjami do liścia (czyli nie ma potomków co reprezentuję wartość -1), to zapisujemy odczytany znak, zwiększamy iter, który jest licznikiem zapisanych znaków oraz ustawiamy node na korzeń drzewa, aby przystąpić do wczytywania kolejnego znaku. Ma to związek z teorią, ponieważ tablica kodowa jest wykonywana w bardzo podobny sposób na podstawie drzewa.

4. Funkcja main.

Funkcja main jest odpowiedzialna za uruchamianie kolejnych funkcji w poprawnej sekwencji oraz kontrolowaniu interfejsu dla użytkownika. Ważne jest to, przy opcji kompresji, że do nazwy tworzy inne nazwy pliku na podstawie pliku wyjściowego dopisując do niego ".code" ".graf" ".model" za pomocą funkcji z biblioteki string o nazwie strcat, a w dekompresji na podstawie pliku wejściowego tworzy nazwę pliku z drzewem dopisując ".graf" do jego nazwy i robi to również za pomocą funkcji strcat.

```
int main() {
       int option = 1;
   while (1)
       printf("Tik Laboratorium nr 3\n1. Kompresjia\n2. Dekompresja\n3.Wyjscie\n-->");
       scanf("%d", &option);
        if (option == 1) {
               printf("Plik wejsciowy: ");
               scanf("%s", inputFile);
               printf("Plik wyjsciowy: ");
               scanf("%s", outputFile);
               strcpy(outputFileCodeTab, outputFile);
               strcat(outputFileCodeTab, ".code");
               strcpy(outputFileTreeF, outputFile);
               strcat(outputFileTreeF, ".graf");
               strcpy(outputFileModel, outputFile);
               strcat(outputFileModel, ".model");
               int iter, checkSum, root;
                    struct HuffmanNode* huffmanModelArray = (HuffmanNode*)malloc(sizeof(HuffmanNode) * 1);
                   huffmanModelArray = GenerateModelFromFile(huffmanModelArray, &iter, &checkSum);
                    //printf("%d", iter);
                   SortHuffmanModel(iter, huffmanModelArray);
                   //printf("Po sortowaniu: checkSum: %d\n", checkSum);
                   int i:
                   //for (i = 0; i < iter; i++) {
                     // printf("%d:%d\n", huffmanModelArray[i].symbol, huffmanModelArray[i].frequency);
                   WriteModelToFile(iter, huffmanModelArray);
                   printf("\n\nModel zrodla zostal zapisany do pliku.\n");
                   huffmanModelArray = GenerateHuffmanTreeFromModel(huffmanModelArray, iter, checkSum, &root);
                   int* arr:
                   arr = (int*)malloc(sizeof(int) * iter);
                   int top = 0;
                    //for (i = 0; i <= root; i++) {
                     // printf("%d parent: %d, symbol: %d,lewy: %d, prawy: %d\n",i, huffmanModelArray[i].frequency, hu
                    WriteHuffmanTreeToFile(huffmanModelArray, root);
                    printf("Drzewo kodowania + ");
                   FILE *fileForCode;
                   if ((fileForCode = fopen(outputFileCodeTab, "w")) == NULL) {
                       printf("Otwieranie pliku do zapisu %s nie powiodlo sie\n", outputFileCodeTab);
                    GenerateCodeTableFromTree(root, arr, top, huffmanModelArray, fileForCode);
                    printf("tablica kodowa zostaly zapisane do pliku.\n");
                    //printf("ok root: %d ", root);
                    //WriteDecompressedFile(huffmanModelArray, huffmanModelArray[root].frequency, root);
                    free(huffmanModelArray):
                       fclose(fileForCode);
                       int sizeCodeTable;
                       struct CodeDock *code = CodeDockCreate(&sizeCodeTable);
                       int j, calc = 0;
                       /*for(i = 0; i < sizeCodeTable; i++) {</pre>
                               printf("%c-0x%X %d", code[i].sign, code[i].code, code[i].current);
                               putc('\n', stdout);
                        //printf("ok2");
                       WriteCompressedFile(code, sizeCodeTable);
                       printf("Kompresja zakonczona\n\n\n");
                       //printf("ok4");
                       free(code);
               3
```

```
else if (option == 2){
                                                            printf("Plik wejsciowy: ");
                                     scanf("%s", inputFile);
                                     printf("Plik wyjsciowy: ");
                                     scanf("%s", outputFile);
                                     strcpy(outputFileTreeF, "");
                                     strcpy(outputFileTreeF, inputFile);
                                     strcat(outputFileTreeF, ".graf");
                                                            struct HuffmanNode* huffmanModelArray = (HuffmanNode*)malloc(sizeof(HuffmanNode) * 1);
                                                            int size;
                                                            huffmanModelArray = ReadHuffmanTreeFromFile(&size);
                                                            int i;
                                                             /*for (i = 0; i < size; i++) {
                                                            printf("%d:%d lewy: %d, prawy: %d parent: %d\n", huffmanModelArray[i].symbol, huffmanModelArray[i].symb
                                                            }*/
                                                 size -= 1;
                                                WriteHuffmanTreeToFileTemp(huffmanModelArray, size);
                                                //struct HuffmanNode *code, FILE *inFileH, FILE *outFileH, int limes, int root
                                                WriteDecompressedFile(huffmanModelArray, huffmanModelArray[size].frequency, size);
                                                //WriteDecompressedFile(huffmanModelArray, huffmanModelArray[size].frequency, size);
                                                //printf("%d", huffmanModelArray[size].parent);
                                                printf("\n\nDekompresja zakonczona\n\n\n");
                                                             free(huffmanModelArray);
                                     }
                                     else {
                                                            return 0;
                                     }
return 0;
```

Rysunek 23. Funkcja main.

5. Podsumowanie.

5.1. Przykład działania programu.

Poniżej przedstawiam zrzuty ekranu z działania programu dla pliku test.txt, który był wykorzystany do prezentacji działania programu na zajęciach.

Ekran terminalu dla wyboru opcji 1. Kompresja:

```
Tik Laboratorium nr 3

In Compresja

Dekompresja

Drzewo kodowania + tablica kodowa zostaly zapisane do pliku.

Kompresja zakonczona

Tik Laboratorium nr 3

Kompresja

Dekompresja

Dekompresja
```

Utworzone pliki:

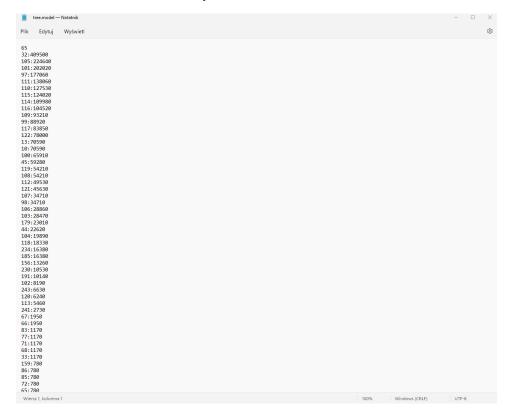
tree tree	S	12.06.2022 00:06	Plik	1 579 KB
tree.code	S	12.06.2022 00:06	Plik CODE	1 KB
tree.graf	S	12.06.2022 00:06	Plik GRAF	7 KB
tree.model	£	12.06.2022 00:06	Plik MODEL	1 KB

Ekran terminalu dla wyboru opcji 2. Dekompresja:

Utworzone pliki:

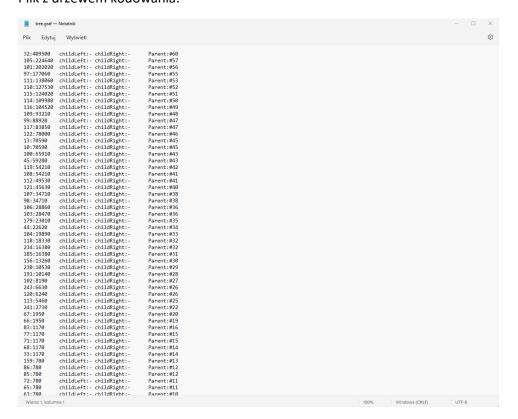
test.txt.decompressed	S	12.06.2022 00:08	Plik DECOMPRESS	2 693 KB
tree tree	£	12.06.2022 00:06	Plik	1 579 KB
tree.code	S	12.06.2022 00:06	Plik CODE	1 KB
tree.graf	S	12.06.2022 00:06	Plik GRAF	7 KB
tree.model	S	12.06.2022 00:06	Plik MODEL	1 KB

Plik z modelem źródła informacji:

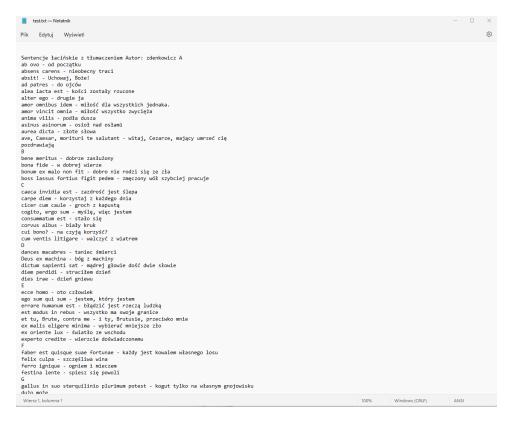


Plik z tablicą kodową:

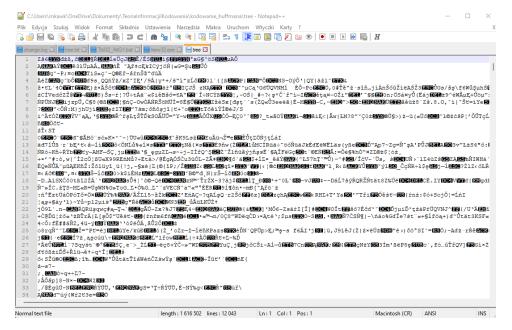
Plik z drzewem kodowania:



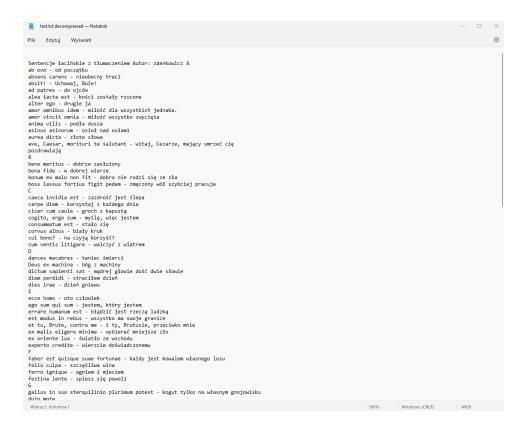
Plik do kompresji:



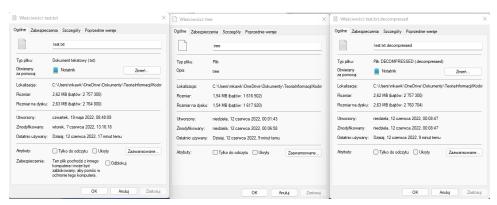
Plik skompresowany:



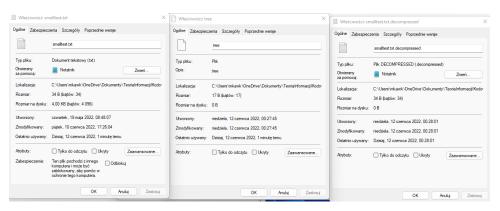
Plik zdekompresowany:



Porównanie wielkości pliku przed kompresją, skompresowanego oraz zdekompresowanego:



Porównanie wielkości pliku przed kompresją, skompresowanego oraz zdekompresowanego dla małego pliku:



5.2. Wnioski.

Jak widać na powyższym przykładzie, kompresja jest efektywna zarówno dla małych i dużych plików. Największy wpływ na jakość kompresji ma ilość różnych znaków, ponieważ im ich mniej tym mniejsze drzewo kodowe, a co za tym idzie, krótsze kody znaków.

Ważną kwestią przy implementacji kodowania Huffmana jest to, że kody znaków mogą być dłuższe od oryginalnych kodów. W takim przypadku należy zastosować "unsigned int" zamiast "unsigned char".

Przedstawiony program działa poprawnie dla dużych oraz małych plików, a po dekompresji plik jest dokładnie taki sam jak przed kompresją.